

TRƯỜNG ĐẠI HỌC CÔNG NGHỆ KỸ THUẬT
TP. HỒ CHÍ MINH
Khoa Điện - Điện tử
Bộ môn Điện tử - Thông tin

Thực hành Học máy và Trí tuệ nhân tạo

Bài 1: Machine Learning for Classification

Giảng viên: TS. Huỳnh Thế Thiện & PGS. TS Trương Ngọc Sơn

Tháng 03, 2026

1 Mục tiêu

Sau khi hoàn thành bài thực hành này, sinh viên có thể:

- Hiểu bài toán classification
- Thực hiện pipeline machine learning cơ bản
- Huấn luyện và đánh giá mô hình phân loại

2 Dataset

Dataset sử dụng: Titanic Dataset trên Kaggle.

Bài toán: dự đoán hành khách sống sót hay không.

3 Phân tích dữ liệu ban đầu (Exploratory Data Analysis)

Trước khi huấn luyện mô hình machine learning, cần phải hiểu cấu trúc của dữ liệu. Quá trình này được gọi là **Exploratory Data Analysis (EDA)**.

EDA giúp trả lời các câu hỏi:

- Dataset có bao nhiêu mẫu?
- Có những đặc trưng nào?
- Có dữ liệu thiếu hay không?
- Phân bố của các đặc trưng như thế nào?
- Các đặc trưng có liên quan đến biến mục tiêu hay không?

3.1 Kiểm tra kích thước dataset

```
print("Train shape:", train.shape)
print("Test shape:", test.shape)
```

Kết quả dự kiến:

- Train dataset: khoảng 891 mẫu
- Test dataset: khoảng 418 mẫu

3.2 Xem các dòng dữ liệu đầu tiên

```
train.head()
```

Lệnh này giúp hiểu cấu trúc của dataset.

Các cột quan trọng:

- Survived : biến mục tiêu
- Pclass : hạng vé
- Sex : giới tính
- Age : tuổi
- Fare : giá vé

3.3 Thống kê dữ liệu

```
train.describe()
```

Kết quả thống kê cung cấp các thông tin:

- giá trị trung bình
- độ lệch chuẩn
- giá trị nhỏ nhất
- giá trị lớn nhất

Những thông tin này giúp phát hiện:

- outliers
- phân bố dữ liệu

4 Phân tích biến mục tiêu

Trước khi huấn luyện mô hình, cần kiểm tra sự cân bằng của dữ liệu.

```
sns.countplot(x='Survived', data=train)
plt.title("Distribution of Survival")
plt.show()
```

Phân tích:

- Nếu dữ liệu mất cân bằng nghiêm trọng thì accuracy không còn là metric tốt.
- Dataset Titanic tương đối cân bằng.

5 Phân tích mối quan hệ giữa đặc trưng và biến mục tiêu

5.1 Survival theo giới tính

```
sns.countplot(x='Sex', hue='Survived', data=train)
plt.show()
```

Phân tích:

- Phụ nữ có tỉ lệ sống sót cao hơn nam giới.
- Điều này phản ánh quy tắc “women and children first”.

5.2 Survival theo hạng vé

```
sns.countplot(x='Pclass', hue='Survived', data=train)
plt.show()
```

Phân tích:

- Hành khách hạng 1 có tỉ lệ sống sót cao hơn.
- Điều này cho thấy Pclass là đặc trưng quan trọng.

5.3 Phân bố tuổi

```
sns.histplot(train['Age'], bins=30)
plt.title("Age Distribution")
plt.show()
```

Phân tích:

- Phần lớn hành khách nằm trong khoảng 20–40 tuổi.
- Có một số lượng nhỏ trẻ em.

6 Xử lý dữ liệu thiếu

Dữ liệu thiếu là vấn đề rất phổ biến trong machine learning.

Kiểm tra dữ liệu thiếu:

```
train.isnull().sum()
```

Các cột thường bị thiếu:

- Age
- Cabin
- Embarked

6.1 Xử lý cột Age

Một phương pháp đơn giản là thay bằng giá trị trung bình.

```
train['Age'].fillna(train['Age'].mean(), inplace=True)
test['Age'].fillna(test['Age'].mean(), inplace=True)
```

6.2 Xử lý cột Embarked

```
train['Embarked'].fillna(train['Embarked'].mode()[0],
                          inplace=True)
```

Mode là giá trị xuất hiện nhiều nhất.

7 Feature Engineering

Feature engineering là quá trình tạo thêm các đặc trưng mới để giúp mô hình học tốt hơn.

Một feature hữu ích trong dataset Titanic là kích thước gia đình.

```
train['FamilySize'] = train['SibSp'] + train['Parch'] + 1
test['FamilySize'] = test['SibSp'] + test['Parch'] + 1
```

Giải thích:

- SibSp: số anh chị em hoặc vợ/chồng
- Parch: số cha mẹ hoặc con cái
- +1 để tính bản thân hành khách

8 Chuẩn bị dữ liệu cho mô hình

8.1 Encode biến categorical

```
le = LabelEncoder()

train['Sex'] = le.fit_transform(train['Sex'])
test['Sex'] = le.transform(test['Sex'])
```

8.2 Chọn đặc trưng

```
features = [
    'Pclass',
    'Sex',
    'Age',
    'Fare',
    'FamilySize'
]
```

9 Huấn luyện mô hình

9.1 Chia tập train và validation

```
X = train[features]
y = train['Survived']

X_train, X_val, y_train, y_val = train_test_split(
    X, y, test_size=0.2, random_state=42
)
```

10 Đánh giá mô hình

Ngoài accuracy, cần xem thêm:

- precision
- recall
- F1-score

```
print(classification_report(y_val, pred_rf))
```

11 Lý thuyết

11.1 Bài toán Classification

Classification là bài toán dự đoán nhãn rời rạc.

Ví dụ:

Bài toán	Nhãn
Spam email	spam / not spam
Chẩn đoán bệnh	bệnh / không bệnh
Titanic	sống / chết

11.2 Logistic Regression

Xác suất được tính:

$$P(y = 1|x) = \frac{1}{1 + e^{-w^T x}}$$

12 Code mẫu

12.1 Import thư viện

```
import numpy as np
import pandas as pd

import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.model_selection import train_test_split
```

```

from sklearn.preprocessing import LabelEncoder

from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.ensemble import RandomForestClassifier

from sklearn.metrics import accuracy_score

```

12.2 Load dataset

```

train = pd.read_csv('/kaggle/input/titanic/train.csv')
test = pd.read_csv('/kaggle/input/titanic/test.csv')

train.head()

```

12.3 Tiền xử lý dữ liệu

```

train['Age'].fillna(train['Age'].mean(), inplace=True)
test['Age'].fillna(test['Age'].mean(), inplace=True)

```

12.4 Encode dữ liệu

```

le = LabelEncoder()

train['Sex'] = le.fit_transform(train['Sex'])
test['Sex'] = le.transform(test['Sex'])

```

12.5 Chọn feature

```

features = ['Pclass', 'Sex', 'Age', 'SibSp', 'Parch', 'Fare']

X = train[features]
y = train['Survived']

```

12.6 Train / Test split

```

X_train, X_val, y_train, y_val = train_test_split(
    X, y, test_size=0.2, random_state=42)

```

13 Huấn luyện mô hình

13.1 Logistic Regression

```
model = LogisticRegression()

model.fit(X_train, y_train)

pred = model.predict(X_val)

print("Accuracy:", accuracy_score(y_val, pred))
```

13.2 Decision Tree

```
tree = DecisionTreeClassifier(max_depth=4)

tree.fit(X_train, y_train)

pred_tree = tree.predict(X_val)

print("Accuracy:", accuracy_score(y_val, pred_tree))
```

13.3 Random Forest

```
rf = RandomForestClassifier(n_estimators=100)

rf.fit(X_train, y_train)

pred_rf = rf.predict(X_val)

print("Accuracy:", accuracy_score(y_val, pred_rf))
```

14 Bài tập

14.1 Bài tập 1: Data Exploration

Thực hiện các bước sau:

- In kích thước của train và test dataset
- Liệt kê tất cả các cột có missing values
- Tính tỷ lệ phần trăm dữ liệu thiếu của từng cột

Gợi ý:

```
train.isnull().sum()
```

14.2 Bài tập 2: Visualization

Vẽ các biểu đồ sau:

- Age distribution
- Fare distribution
- Survival theo Sex
- Survival theo Pclass

Sinh viên cần nhận xét ý nghĩa của từng biểu đồ.

14.3 Bài tập 3: Missing Data Handling

Xử lý các cột sau:

- Cabin
- Embarked

Giải thích vì sao chọn phương pháp xử lý đó.

14.4 Bài tập 4: Feature Engineering

Tạo các feature mới:

- FamilySize
- IsAlone

Gợi ý:

```
train['IsAlone'] = (train['FamilySize']==1).astype(int)
```

14.5 Bài tập 5: Title Extraction

Trích xuất title từ cột Name.

Ví dụ:

```
train['Title'] = train['Name'].str.extract('([A-Za-z]+)\.')
```

Sau đó encode feature này.

14.6 Bài tập 6: Correlation Analysis

Vẽ heatmap của correlation matrix.

```
sns.heatmap(train.corr(), annot=True)
```

Trả lời câu hỏi:

Feature nào tương quan mạnh nhất với Survived?

14.7 Bài tập 7: Model Comparison

Huấn luyện các mô hình sau:

- Logistic Regression
- Decision Tree
- Random Forest
- K-Nearest Neighbors
- Support Vector Machine

So sánh accuracy của các mô hình.

14.8 Bài tập 8: Hyperparameter Tuning

Sử dụng GridSearchCV để tìm tham số tốt nhất cho Random Forest.

Thử các giá trị:

- `n_estimators = 50,100,200`
- `max_depth = 3,5,10`

14.9 Bài tập 9: Cross Validation

Sử dụng k-fold cross validation với k=5 để đánh giá mô hình.

Gợi ý:

```
from sklearn.model_selection import cross_val_score
```

14.10 Bài tập 10: Feature Importance

Vẽ biểu đồ feature importance của Random Forest.

Gợi ý:

```
importances = rf.feature_importances_
```

Sinh viên cần trả lời:

Feature nào quan trọng nhất đối với mô hình?

So sánh 3 mô hình:

- Logistic Regression
- Decision Tree
- Random Forest

15 Câu hỏi

1. Vì sao Logistic Regression hoạt động tốt?
2. Khi nào Decision Tree bị overfitting?
3. Vì sao Random Forest tốt hơn Decision Tree?